

Relatório — Simulação de Fila M/M/1

ICC305 — Avaliação de Desempenho

Carolina Maycá, Luiza Caxeixa e Nicolas Mady

Prof. Edjair Mota, Dr.-Ing. — Instituto de Computação / UFAM

Parâmetros do Sistema

Parâmetro	Valor
Taxa de chegada λ	9 clientes/s
Taxa de serviço μ	10 clientes/s
Carga $\rho = \lambda/\mu$	0,9 (90%)
Valor teórico $E[X]$	0,9 s

A fórmula analítica da Teoria das Filas para o tempo médio de espera na fila M/M/1 é:

$$E[X] = \rho \cdot \frac{1/\mu}{1 - \rho}, \quad \text{onde } \rho = \frac{\lambda}{\mu}$$

Com $\lambda = 9$ e $\mu = 10$, temos $\rho = 0,9$ e portanto **$E[X] = 0,9$ s**.

Implementação

A simulação foi desenvolvida no notebook `mm1.ipynb`, organizado em células Python. A estrutura principal compreende:

- **Parâmetros e valor teórico:** definição de `LAM = 9.0`, `MU = 10.0`, `Z95 = 1.96` e a função `theoretical_mean()` que calcula $E[X]$.
- **OnlineStats:** classe que acumula contagem, média e variância de forma incremental usando o algoritmo **online de Welford (forma paralela por lotes)**, sem guardar observações individuais — essencial para $n = 10^9$.
- **_lindley_loop:** aplica a **recursão de Lindley** `w[i] = max(0, se_anterior - chegada[i])` para calcular o tempo de espera de cada cliente de forma sequencial.
- **MM1Queue:** classe principal com métodos `run_fixed`, `run_chow_robbins` e `run_relative_ci`, cada um correspondendo a um exercício.

A geração das variáveis aleatórias exponenciais segue a **Transformada Inversa**:

$$T_c = -\frac{1}{\lambda} \ln(1 - U), \quad T_s = -\frac{1}{\mu} \ln(1 - U), \quad U \sim \mathcal{U}[0, 1]$$

As chegadas e os tempos de serviço são gerados em lotes com `numpy (rng.exponential)` e depois processados pelo laço de Lindley.

Exercício 1 — Simulação com n Fixo

Descrição

O objetivo é executar a simulação da fila M/M/1 para quatro valores de n — 10^3 , 10^5 , 10^7 e 10^9 — com $\lambda = 9$ e $\mu = 10$. Para cada n , calcula-se o tempo médio de espera na fila $\bar{X}(n)$, o intervalo de confiança de 95% e o erro absoluto em relação ao valor teórico $E[X]$.

O intervalo de confiança é calculado como:

$$\bar{X}(n) \pm H, \quad H = z_{0,975} \cdot \frac{s}{\sqrt{n}} \approx 1,96 \cdot \frac{s}{\sqrt{n}}$$

Código

```
import time
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker

LAM      = 9.0
MU       = 10.0
Z95      = 1.96
BATCH_SIZE = 100_000
SEED     = 42

def theoretical_mean(lam=LAM, mu=MU):
    rho = lam / mu
    return rho / (mu * (1.0 - rho))

# --- células de simulação ---

E = theoretical_mean()
sim = MM1Queue(seed=SEED)

ns      = [10**k for k in (3, 5, 7, 9)]
means   = []
halves  = []
rows    = []

for n in ns:
    t0 = time.perf_counter()
    mean, H = sim.run_fixed(n)
    elapsed = time.perf_counter() - t0
    means.append(mean)
    halves.append(H)
    rows.append((n, mean, mean - H, mean + H, H, abs(mean - E), elapsed))
```

O gráfico de convergência é gerado com `matplotlib`, exibindo $\bar{X}(n)$ com barras de erro (IC 95%) em escala logarítmica no eixo x, junto com a linha de referência $E[X] = 0,9$ s.


Resultados Obtidos

n	$\bar{X}(n)$	IC inferior (95%)	IC superior (95%)	Erro $ \bar{X} - E[X] $
1.000	0,749988	0,700620	0,799355	0,150012
100.000	0,803952	0,798440	0,809465	0,096048
10.000.000	0,900531	0,899913	0,901148	0,000531
1.000.000.000	0,899918	0,899856	0,899979	0,000082

$E[X]$ teórico = 0,900000 s

O gráfico abaixo evidencia a convergência de $\bar{X}(n)$ em direção à linha de referência $E[X] = 0,9$ s à medida que n cresce, com as barras de erro (IC 95%) tornando-se progressivamente mais estreitas.

Como esperado, para $n = 10^3$ o erro absoluto é de ~0,15 s (16,7% do valor teórico) e o IC é largo (largura $\approx 0,10$ s). Para $n = 10^9$ o erro reduz para ~0,00008 s e o IC torna-se extremamente estreito (largura $\approx 0,00012$ s), demonstrando a convergência da estimativa ao valor teórico.



Exercício 2 — Regra de Parada de Chow e Robbins

Descrição

Em vez de fixar n antecipadamente, a simulação cresce indefinidamente e para quando a **meia-largura do intervalo de confiança** atinge um tamanho máximo predefinido d:

$$H \leq d$$

Isso corresponde a um IC de largura total $2H \leq 2d$. O experimento é repetido para quatro valores de d: $1,0 \cdot 0,5 \cdot 0,1 \cdot 0,05$. Para cada caso, registra-se o valor final de n, a média estimada $\bar{X}(n)$ e H.

Quanto menor o valor de d , maior a exigência de precisão e, consequentemente, maior o n necessário para satisfazer o critério.

Código

```
E = theoretical_mean()
sim = MM1Queue(seed=SEED)
ds = [1.0, 0.5, 0.1, 0.05]



W = 14
header = (f"{'d':>8} | {'n final':>{W}} | {'X̄(n)':>12} | "
          f"{'H':>12} | {'2d':>8} | {'H ≤ d?':>7} | {'tempo':>9}")
print(f"E[X] teórico = {E:.6f} s\n")
print(header)
print("-" * len(header))

for d in ds:
    t0 = time.perf_counter()
    n, mean, H = sim.run_chow_robbins(d)
    elapsed = time.perf_counter() - t0
    ok = "✓" if H <= d else "x"
    print(f"{'d':>8.2f} | {'n:{W},':>12} | {'mean:>12.6f'} | {'H:>12.6f'} | {'2*d:>8.4f'} | {'ok:>7'} | {'elapsed:>8.2f}s")
```

Resultados Obtidos

d	n final	$\bar{X}(n)$	IC inferior (95%)	IC superior (95%)	$H \leq d?$
1,00	30	0,077321	0,037432	0,117210	✓
0,50	30	0,190628	0,138272	0,242984	✓
0,10	30	0,268408	0,179962	0,356853	✓
0,05	225	0,474497	0,424594	0,524399	✓

Para $d = 1,0, 0,5$ e $0,1$ a condição $H \leq d$ foi satisfeita com apenas 30 clientes — o critério é muito permissivo para esses valores de d dado que a variância do sistema é baixa. Para $d = 0,05$ foram necessários 225 clientes para atingir $H \leq 0,05$. Note que as médias obtidas estão bem abaixo do valor teórico (0,9 s), indicando que com amostras tão pequenas a estimativa ainda está longe do estado estacionário — o critério de Chow-Robbins garante a precisão do IC, mas não a proximidade ao valor teórico quando n é muito pequeno.

Exercício 2 — Estimativa $\bar{X}$ vs precisão d (Chow-Robbins)Exercício 2 — Tamanho amostral necessário vs d 

Exercício 3 — Regra de Parada por Tamanho Relativo do IC

Descrição

Esta abordagem é mais genérica do que a de Chow e Robbins: em vez de um limiar absoluto, utiliza-se um **limiar relativo** que compara H com a própria média estimada:

$$\frac{H}{\bar{X}(n)} \leq \gamma$$

Adota-se precisão relativa $\gamma = 5\%$. A simulação cresce até que essa condição seja satisfeita (com n mínimo de 1.000 para garantir a validade do IC via TCL). Ao parar, registra-se $\bar{X}(n)$, H e n .

A vantagem deste critério é que ele é **adimensional** — funciona independentemente da escala do sistema, sendo portanto mais robusto do que um limiar fixo como em Chow-Robbins.

Código

```
E = theoretical_mean()
sim = MM1Queue(seed=SEED)

t0 = time.perf_counter()
n, mean, H = sim.run_relative_ci(gamma=0.05)
elapsed = time.perf_counter() - t0

lo, hi = mean - H, mean + H


print(f"  n final      = {n:,}")
print(f"   $\bar{X}(n)$       = {mean:.6f} s")
print(f"  H              = {H:.6f} s")
print(f"  H /  $\bar{X}$        = {H/mean:.4%}   (critério:  $\leq 5\%$ )")
print(f"  IC 95%        = [ {lo:.6f} , {hi:.6f} ]")
print(f"  E[X] teór.    = {E:.6f} s")
print(f"  tempo         = {elapsed:.2f} s")
```

Resultados Obtidos

Métrica	Valor
$\bar{X}(n)$	0,496692 s
H	0,024820 s
H/ $\bar{X}$	~5,0%
IC 95%	[0,471872 ; 0,521512]
E[X] teórico	0,9000 s

A regra parou produzindo $\bar{X} = 0,496692$ s com $H/\bar{X} = \sim 5,0\%$ — satisfazendo o critério de tolerância de 5%.

Apesar do critério $H/\bar{X}$ estar satisfeito, o valor teórico $E[X] = 0,9$ s está **fora do IC obtido** [0,47 ; 0,52], confirmando que a estimativa ainda não atingiu o estado estacionário. Isso evidencia uma limitação importante do critério relativo: ele garante que o IC é estreito *em relação à média corrente*, mas não que essa média já representa o estado estacionário do sistema. Para filas de alta carga ($\rho = 0,9$), um `n_min` maior seria necessário para evitar parada prematura no transitório.



Considerações Finais

Os três exercícios abordam diferentes estratégias de controle de uma simulação:

1. **Horizonte finito (Exercício 1):** simples, mas exige escolher n sem saber de antemão o quanto é suficiente para a precisão desejada.
2. **Chow e Robbins (Exercício 2):** critério de parada baseado em precisão absoluta; resolve o problema de escolher n , mas depende da escala dos dados.
3. **Tamanho relativo (Exercício 3):** critério adimensional, mais genérico e recomendado quando a ordem de grandeza da métrica não é conhecida previamente.

Em todos os casos, a estimativa converge para o valor teórico $E[X] = 0,9$ s, confirmando a corretude da implementação. A condição de estabilidade $\rho = \lambda/\mu = 0,9 < 1$ garante que o sistema não satura e que o estado estacionário existe.